

ΑΣΚΗΣΗ ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ ΜΕΡΟΣ Α

Κυριακούlopoulos Καλλίνικος
ΑΜ: 1084583

Contents

.....	0
A1. Προεπεξεργασία και Προετοιμασία Δεδομένων	2
a) Κωδικοποίηση και Προεπεξεργασία Δεδομένων	2
b) Κανονικοποίηση.....	3
c) Διασταυρούμενη Επικύρωση	3
A2. Επιλογή αρχιτεκτονικής.....	3
a) Συνάρτηση σφάλματος.....	3
b) Συνάρτηση ενεργοποίησης κρυφών κόμβων	3
c) Συνάρτηση ενεργοποίησης εξόδου	3
d) Αριθμός κόμβων κρυφού επιπέδου	3
e) Αριθμός κρυφών επιπέδων.....	5
f) Κριτήριο τερματισμού	6
A3. Μεταβολές στον ρυθμό εκπαίδευσης και σταθεράς ορμής.....	7
A4. Ομαλοποίηση	11

Τον κώδικα θα τον βρείτε σε shared folder του onedrive εδώ: [github-copy](#)

Ανάλυση περιεχομένου:

Ann.py: το κύριο αρχείο με το νευρωνικό δίκτυο.

Data_preprocessing.py: το αρχείο που πραγματοποιείται η μετατροπή των επιγραφών σε vectors και εξάγει το αρχείο preprocessed_data.csv που χρησιμοποιείται στο νευρωνικό δίκτυο

Convergence.py: το πρόγραμμα αυτό παίρνει τα σημεία από τον φάκελο convergence που είναι αποθηκευμένα σε .json μορφή. Τα σημεία προκύπτουν από την εκπαίδευση κάθε δικτύου από την γραφική παράσταση loss στην εκπαίδευση για κάθε fold. Το όνομα των json προκύπτει ως εξής points{num of layers}{num of nodes}{fold}.json. Παράδειγμα για δίκτυο με ένα κρυφό επίπεδο και 5 νευρώνες στο κρυφό επίπεδο και fold=0: points150.json

Ο φάκελος convergence_plot περιέχει τα γραφήματα που έχουν παραχθεί από το πρόγραμμα convergence.py. Το πρόγραμμα χρησιμοποιήθηκε για τα figures 1,2,3,4,5,6 της αναφοράς.

Ο φάκελος figures περιέχει τα γραφήματα που προκύπτουν από τη γραφική παράσταση του loss. Αντιστοιχεί ένα figure για κάθε fold.

Για την πραγματοποίηση των ερωτημάτων χρησιμοποιούνται στον κώδικα σταθερές στις οποίες γινόταν ανάθεση τιμής ανάλογα με το ζητούμενο.

```
# Number of nodes in hidden layer
NUM_OF_NODES = 30
# Number of hidden layers
NUM_OF_LAYERS = 1
# Dimension of input
X_DIM = 1001
# Learning rate of model
LEARNING_RATE = 0.001
# Momentum of model
MOMENTUM = 0.2
# Probability to drop nodes in the input layer
RI = 0.9
# Probability to drop nodes in the hidden layer
RH = 0.8
```

A1. Προεπεξεργασία και Προετοιμασία Δεδομένων

a) Κωδικοποίηση και Προεπεξεργασία Δεδομένων

Χρησιμοποιήθηκε η βιβλιοθήκη sklearn για tokenization και vectorization των κειμένων. Από τα κείμενα προέκυψαν tokens τα οποία είναι οι λέξεις από τις οποίες αποτελούνται και τα tokens με χρήση tf-idf μετατράπηκαν σε αριθμούς. Επομένως κάθε κείμενο μετατράπηκε σε διάνυσμα ώστε να μπορεί να είναι είσοδος στο ann. Επίσης από τα tokens που προέκυψαν κρατήθηκαν τα 1000 πιο συχνά εμφανιζόμενα με ελάχιστο αριθμό εμφανίσεων 7. Τέλος για την εκπαίδευση έχει χρησιμοποιηθεί και η στήλη region_main_id.

b) Κανονικοποίηση

Πριν την εφαρμογή των εισόδων στο δίκτυο γίνεται κανονικοποίηση με χρήση min-max στα δεδομένα εισόδου και στις εξόδους. Τα διανύσματα εισόδου και οι εξοδοί που προκύπτουν έχουν τιμές στο $[0,1]$ έτσι ώστε να μην υπάρχουν μεγάλες τιμές και να είναι προσαρμοσμένες στο σύνολο τιμών των συναρτήσεων ενεργοποίησης.

c) Διασταυρούμενη Επικύρωση

Για την εκπαίδευση του δικτύου χρησιμοποιείται η τεχνική cross validation. Το σύνολο δεδομένων χωρίζεται σε 5 μέρη και σε κάθε κύκλο εκπαίδευσης ένα από αυτά τα σύνολα χρησιμοποιείται για test.

A2. Επιλογή αρχιτεκτονικής

a) Συνάρτηση σφάλματος

Για συνάρτηση σφάλματος έχει χρησιμοποιηθεί η ρίζα του μέσου τετραγωνικού σφάλματος. Επίσης για να ανταποκρίνεται στο πρόβλημα έχει διαφοροποιηθεί έτσι ώστε να ελέγχεται αν η πρόβλεψη στην έξοδο (y_{pred}) ανήκει στο διάστημα που ορίζεται από την ελάχιστη και τη μέγιστη χρονολογία. Αν ανήκει τότε το σφάλμα είναι 0 αλλιώς γίνεται υπολογισμός του σφάλματος με το rmse χρησιμοποιώντας την τιμή y_{pred} και τον μέσο όρο των 2 χρονολογιών ($avg = \frac{min_date + max_date}{2}$).

b) Συνάρτηση ενεργοποίησης κρυφών κόμβων

Για τους κρυφούς κόμβους χρησιμοποιείται η συνάρτηση ενεργοποίησης relu, προτιμήθηκε διότι είναι. Η διαφορισμότητα είναι η μόνη απαίτηση που πρέπει να ικανοποιεί μια συνάρτηση ενεργοποίησης κρυφού επιπέδου σε έναν αλγόριθμο ΠΔ, αυτό απαιτείται για τον υπολογισμό του δ για κάθε νευρώνα. Οι άλλες συναρτήσεις που είναι παραγωγίσιμες μπορεί να πάθουν κορεσμό.

c) Συνάρτηση ενεργοποίησης εξόδου

Για το επίπεδο εξόδου χρειάζεται μόνο ένας κόμβος αφού το πρόβλημα είναι παλινδρόμηση (ζητείται στην έξοδο μία τιμή) και επίσης χρησιμοποιείται ως συνάρτηση ενεργοποίησης η γραμμική. Η έξοδος της συνάρτησης μπορεί να ικανοποιήσει το εύρος τιμών που απαιτείται αφού τα δεδομένα εξόδου έχουν κανονικοποιηθεί στο $[0,1]$ και η γραμμική συνάρτηση ενεργοποίησης παράγει τιμές στο $(-\infty, \infty)$.

d) Αριθμός κόμβων κρυφού επιπέδου

Αριθμός νευρώνων κρυφού επιπέδου	RMSE
H1 = 800	0.9918523907661438
H1 = 100	0.2928304851055145
H1 = 30	0.1728588670492172

Σχετικά με τη σύγκλιση παρατηρώ ότι σχεδόν και οι τρεις περιπτώσεις συγκλίνουν στο ίδιο σημείο, λίγο πιο γρήγορα συγκλίνει το δίκτυο με τους 800 νευρώνες μετά με τους 100 και τέλος με τους 30.

Παρόλα αυτά το δίκτυο με τους 30 νευρώνες στο κρυφό επίπεδο πετυχαίνει το μικρότερο rmse. Τα αποτελέσματα αυτά προκύπτουν διότι το δίκτυο με τους πολλούς νευρώνες είναι πιο γρήγορο στη μάθηση, περισσότεροι νευρώνες περισσότερες συνάψεις, αλλά το δίκτυο με τους λιγότερους νευρώνες πετυχαίνει το μικρότερο σφάλμα γιατί οι είσοδοι που δίνονται έχουν πολλές τιμές σχεδόν 0 οι οποίες νεκρώνουν κάποιους νευρώνες. Επίσης τα δίκτυα με τους πολλούς νευρώνες δεν προσφέρουν γενίκευση.




Figure 1. Convergence of loss (folds 0,1).




Figure 2. Convergence of loss (fold 2).




Figure 3. Convergence of loss (folds 3,4).

H1=800	H1=100	H1=30
Fold: 0 RMSE: 0.9886189699172974	Fold: 0 RMSE: 0.28727638721466064	Fold: 0 RMSE: 0.17694731056690216
Fold: 1 RMSE: 0.9924589395523071	Fold: 1 RMSE: 0.3019762635231018	Fold: 1 RMSE: 0.18033429980278015
Fold: 2 RMSE: 0.9979127049446106	Fold: 2 RMSE: 0.29270267486572266	Fold: 2 RMSE: 0.16890168190002441
Fold: 3 RMSE: 0.992190957069397	Fold: 3 RMSE: 0.28509750962257385	Fold: 3 RMSE: 0.1643877923488617
Fold: 4 RMSE: 0.9880803823471069	Fold: 4 RMSE: 0.29709959030151367	Fold: 4 RMSE: 0.1737232506275177
RMSE: 0.9918523907661438	RMSE: 0.2928304851055145	RMSE: 0.1728588670492172
Num of nodes in hidden layer:800	Num of nodes in hidden layer:100	Num of nodes in hidden layer:30
Num of hidden layers:1	Num of hidden layers:1	Num of hidden layers:1

ε) Αριθμός κρυφών επιπέδων

Η αύξηση των επιπέδων δεν βελτιώνει τη σύγκλιση (στα folds 0 και 2 βελτιώνεται ελάχιστα) και το σφάλμα αυξάνεται. Επομένως το καλύτερο δίκτυο είναι και το απλό (occam's razor).

H1=30	H1=30 H2=30	H1=30 H2=30 H3=30
Fold: 0 RMSE: 0.17694731056690216	Fold: 0 RMSE: 0.1965087503194809	Fold: 0 RMSE: 0.2170296162366867
Fold: 1 RMSE: 0.18033429980278015	Fold: 1 RMSE: 0.20191523432731628	Fold: 1 RMSE: 0.23698823153972626
Fold: 2 RMSE: 0.16890168190002441	Fold: 2 RMSE: 0.19542767107486725	Fold: 2 RMSE: 0.21744520962238312
Fold: 3 RMSE: 0.1643877923488617	Fold: 3 RMSE: 0.20175881683826447	Fold: 3 RMSE: 0.22212687134742737
Fold: 4 RMSE: 0.1737232506275177	Fold: 4 RMSE: 0.19204820692539215	Fold: 4 RMSE: 0.23163364827632904
RMSE: 0.1728588670492172	RMSE: 0.19753173589706421	RMSE: 0.2250447154045105
Num of nodes in hidden layer:30	Num of nodes in hidden layer:30	Num of nodes in hidden layer:30
Num of hidden layers:1	Num of hidden layers:2	Num of hidden layers:3




Figure 4. Coverage of loss (folds 0,1).




Figure 5. Convergence of loss (fold 2).




Figure 6. Convergence of loss (folds 3,4).

Σε αυτή τη δοκιμή παρατηρείται ότι το δίκτυο με το μειούμενο αριθμό νευρώνων στα κρυφά επίπεδα έχει το μικρότερο rmse. Το δίκτυο με τον αυξανόμενο αριθμό κόμβων έχει το μεγαλύτερο rmse.

H1=30 H2=30 H3=30	H1=30 H2=15 H3=6	H1=30 H2=60 H3=150
Fold: 0 RMSE: 0.2170296162366867	Fold: 0 RMSE: 0.19656354188919067	Fold: 0 RMSE: 0.2881367802619934
Fold: 1 RMSE: 0.23698823153972626	Fold: 1 RMSE: 0.18621651828289032	Fold: 1 RMSE: 0.2930324971675873
Fold: 2 RMSE: 0.21744520962238312	Fold: 2 RMSE: 0.2097446322441101	Fold: 2 RMSE: 0.2870733141899109
Fold: 3 RMSE: 0.22212687134742737	Fold: 3 RMSE: 0.19956378638744354	Fold: 3 RMSE: 0.29022979736328125
Fold: 4 RMSE: 0.23163364827632904	Fold: 4 RMSE: 0.20071572065353394	Fold: 4 RMSE: 0.292564332485199
RMSE: 0.2250447154045105	RMSE: 0.19856083989143372	RMSE: 0.29020734429359435
Num of nodes in hidden layer:30	Num of nodes in hidden layer:30	Num of nodes in hidden layer:30
Num of hidden layers:3	Num of hidden layers:3	Num of hidden layers:3

Και από τις 2 δοκιμές συμπεραίνω ότι η αύξηση των κόμβων δεν βελτιώνει ούτε το RMSE ούτε τη σύγκλιση.

f) Κριτήριο τερματισμού


Ο αλγόριθμος τερματίζει όταν ολοκληρωθούν όλες οι εποχές εκπαίδευσης. Στον κώδικα έχουν οριστεί 80 εποχές εκπαίδευσης για κάθε fold. Επίσης για αποφυγή υπερεκπαίδευσης χρησιμοποιείται η τεχνική regularization L2 με παράμετρο 0.001.


Η τεχνική early stopping για τερματισμό της εκπαίδευσης σε κάθε fold δεν μπορεί να εφαρμοστεί. Από κάθε σύνολο εκπαίδευσης θα πρέπει να κρατάμε ένα μέρος για επικύρωση

και αυτό το σύνολο στο επόμενο fold θα χρησιμοποιηθεί στο σύνολο ελέγχου. Επομένως θα υπάρχουν κοινά παραδείγματα για τα σύνολα ελέγχου και επικύρωσης. Για να εφαρμοστεί early stopping πρέπει τα σύνολα εκπαίδευση, επικύρωσης και ελέγχου να μην έχουν κοινά παραδείγματα.


A3. Μεταβολές στον ρυθμό εκπαίδευσης και σταθεράς ορμής


Learning rate = 0.001 momentum = 0.2







Learning rate = 0.001 momentum = 0.6







Learning rate = 0.05 momentum = 0.6





Learning rate = 0.1 momentum = 0.6





Από τα πειράματα παρατηρώ ότι η αλλαγή της ορμής επηρεάζει την ταχύτητα σύγκλισης, όσο αυξάνεται τόσο πιο νωρίς συγκλίνει και η αλλαγή του ρυθμού μάθησης επηρεάζει την ομαλότητα της καμπύλης, όσο αυξάνεται παρατηρούνται μεγαλύτερες διακυμάνσεις.

Για τα σφάλματα που καταγράφηκαν σε κάθε περίπτωση φαίνεται να υπάρχει μικρότερο σφάλμα με την αύξηση του ρυθμού μάθησης και της ορμής (στην ορμή η μείωση είναι μικρή). Αν όμως αυξήσουμε και άλλο το ρυθμό μάθησης το σφάλμα θα μεγαλώσει. (Για ρυθμό μάθησης 0.9 και ορμή 0.6 σημειώνεται σφάλμα 0.31).

Η αλλαγή της ορμής βοηθά τον αλγόριθμο να συγκλίνει πιο γρήγορα. Όμως η τιμή που παίρνει θα πρέπει να ανήκει στο διάστημα $[0,1)$ έτσι ώστε οι πιο παλιές τιμές να έχουν μικρότερη επίδραση στην μεταβολή των βαρών. Αυτό συμβαίνει διότι στον υπολογισμό των βαρών η παράμετρος της ορμής πολλαπλασιάζεται τα προηγούμενα βάρη.


η	m	RMSE
0.001	0.2	0.17089489996433258
0.001	0.6	0.1736661285161972
0.05	0.6	0.1641688734292984
0.1	0.6	0.11878506243228912

A4. Ομαλοποίηση


Πιθανότητες διατήρησης	RMSE
$r_{in}=0.8$ $r_h=0.5$	0.13504188507795334
$r_{in}=0.5$ $r_h=0.5$	0.13543119728565217
$r_{in}=0.8$ $r_h=0.2$	0.1344517022371292

Οι πιθανότητες που υπάρχουν στον πίνακα αναφέρονται στην πιθανότητα διατήρησης των κόμβων του επιπέδου. Στο πρόγραμμα δίνεται σαν παράμετρος η πιθανότητα μη διατήρησης των κόμβων του επιπέδου, για αυτό χρησιμοποιείται η πιθανότητα $1-r$.


$$r_{in}=0.8 \ r_h=0.5$$



$$r_{in}=0.5 \ r_h=0.5$$



$$r_{in}=0.8 \ r_h=0.2$$



Η ικανότητα γενίκευσης αυξάνεται όσο περισσότερους κόμβους έχουμε στο επίπεδο εισόδου, γιατί το όριο σφάλματος αυξάνεται (από θεωρία).

Η αύξηση της πιθανότητας διαγραφής κόμβου μειώνει την ταχύτητα σύγκλισης και μεγαλύτερη επίδραση σε αυτό φαίνεται να έχει η διαγραφή κόμβου από το επίπεδο εισόδου.

Όταν έχουμε τη μεγαλύτερη πιθανότητα διατήρησης των κόμβων εισόδου και τη μικρότερη των κόμβων κρυφού επιπέδου σημειώνεται το μικρότερο σφάλμα.

Τέλος το σφάλμα και στις 3 περιπτώσεις είναι μικρότερο από αυτό του δικτύου χωρίς dropout, αλλά η σύγκλιση δεν είναι.